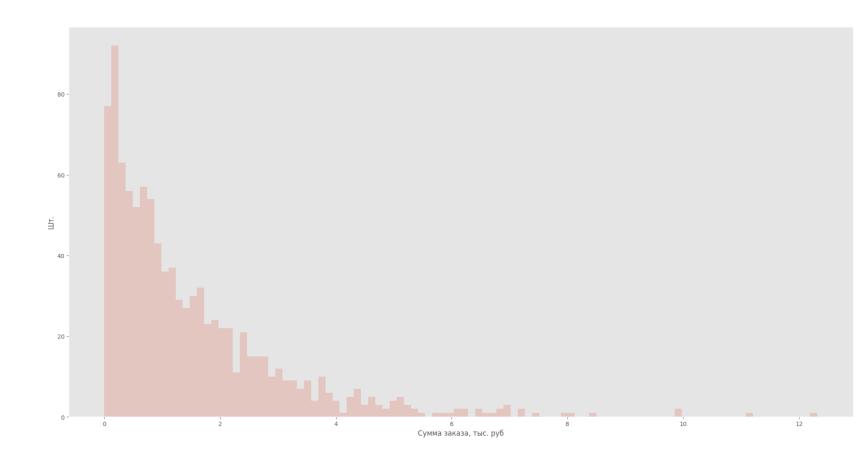
#### Есть интернет магазин

Хотим оценить среднюю сумму заказа, но есть выбросы

Также хотим понимать, по каким ценам покупает большинство пользователей



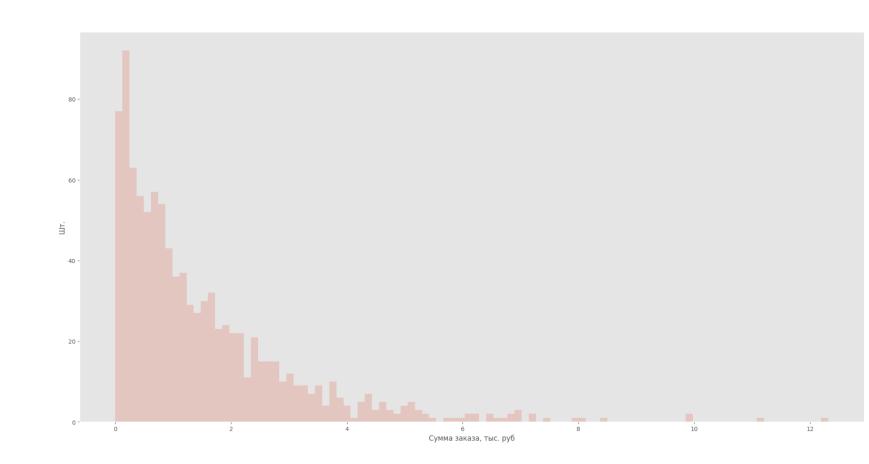
#### Есть интернет магазин

Хотим оценить среднюю сумму заказа, но есть выбросы

Также хотим понимать, по каким ценам покупает большинство пользователей

# Возьмем медиану как оценку среднего

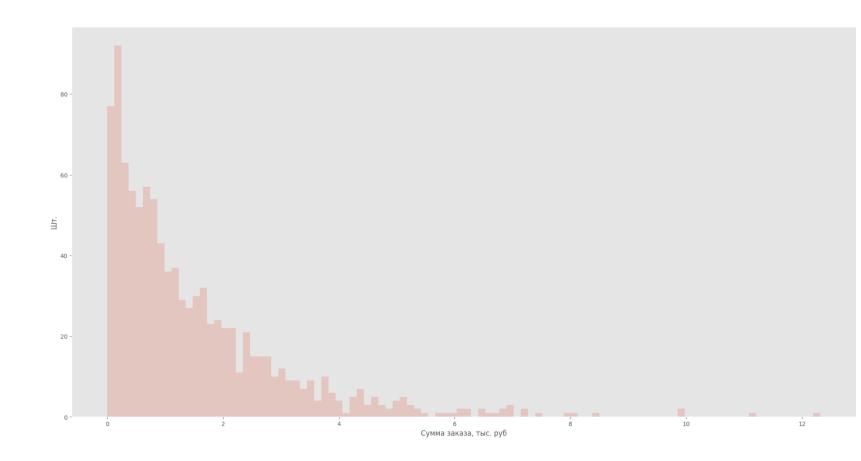
Построим ДИ для медианы, чтобы оценить интервал цен, по которым покупает большинство пользователей



# Возьмем медиану как оценку среднего

Построим ДИ для медианы, чтобы оценить интервал цен, по которым покупает большинство пользователей

Как построить ДИ для медианы?



Обладая только данными по имеющейся выборке, можно оценить любой ее параметр, построив эмпирическое распределение параметра.

В контексте нашей задачи с медианой – получить распределение медиан и далее по ним вычислить доверительный интервал.

#### Выборка

1.2

2.3

3. 14

6.17

Выборка

Повторная бут-выборка

1.2

2.3

3. 14

6.17

Выборка

Повторная бут-выборка

1.2

2.3

2.3

3. 14

6.17

Выборка

Повторная бут-выборка

1.2

2.3

2.3

6.17

3. 14

Выборка Повторная бут-выборка

1.2 2.3

2.3 6.17

3. 14

6.17

Медиана 3.14

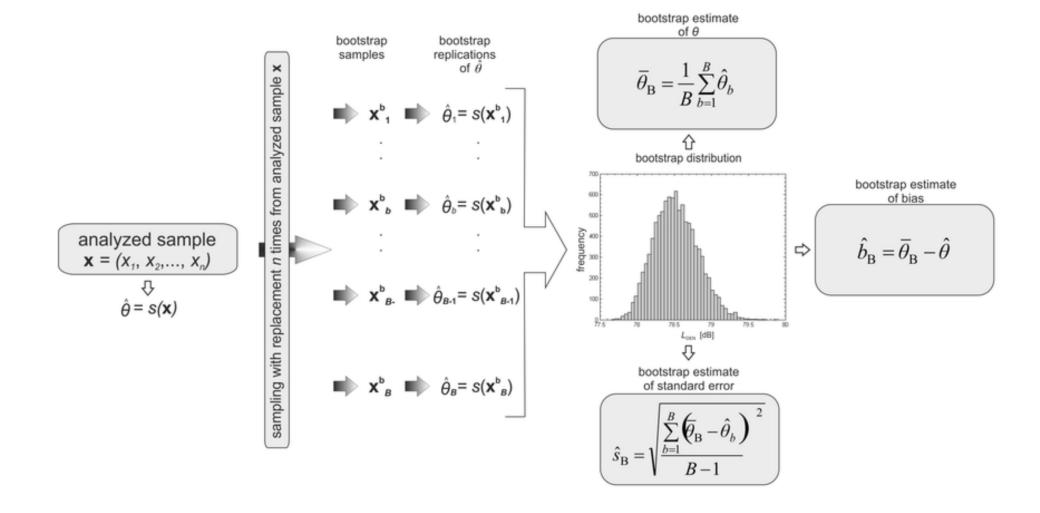
Выборка	Повторная бут-выборка	
1.2	2.3	
2.3	6.17	
3. 14	3.14	
6.17	8.23	
8.23	3.14	

Медиана 3.14

Выборка	Повторная бут-выборка	Повторная бут-выборка	Повторная бут-выборка	Повторная бут-выборка
1.2	2.3	2.3	1.2	1.2
2.3	6.17	6.17	1.2	2.3
3. 14	3.14	2.3	2.3	6.17
6.17	8.23	6.17	2.3	6.17
8.23	3.14	8.23	8.23	8.23
Медиана 3.14	Медиана 3.14	Медиана 6.17	Медиана 2.3	Медиана 6.17

Бутстрап распределение медиан

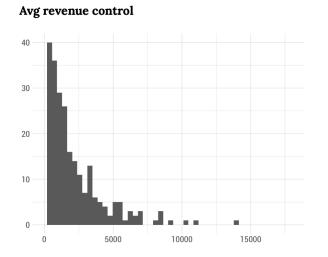
3.14 6.17 2.3 6.17 --> Считаем доверительный интервал --> получаем эмпирическую оценку параметра распределения (медианы)



Почему просто не применить статистический критерий?

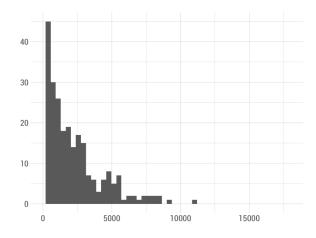
- 1) Манн-Уитни может показать разницу в распределениях, что круто. Но хотелось бы оценить эту разницу, а не просто получить ответ: разные они или нет
- 2) У каждого критерия свое аналитическое решение, которое требует придерживаться ряда допущений (например, одинаковая дисперсия/ одинаковый размер выборки/одинаковая форма распределений и т.п). Такая возможность не всегда имеется

$$\bar{X} = 5253$$



$$\bar{Y} = 5412$$

#### Avg revenue test



С помощью бутстрапа можем взять и оценить любую статистику в этих распределениях: средние, медианы, квантили

Как с помощью бутстрапа проверить гипотезу? (1 способ)

- 1. Строим бутстрап распределения параметров А и В
- 2. Вычисляем разницу (например, разницу медиан)
- 3. В этом распределении разниц строим доверительный интервал
- 4. Смотрим, попадает ли 0 в доверительный интервал. Если да, то нулевая гипотеза не отвергается на заданном уровне значимости

Как с помощью бутстрапа проверить гипотезу? (2 способ)

- 1. Строим бутстрап распределения параметров А и В
- 2. На каждой итерации вычисляем статистику  $T^{*(b)} = \frac{\bar{X}^*(b) \bar{Y}^*(b)}{\frac{s_x^{2*(b)}}{n_x} + \frac{s_y^{2*(b)}}{n_y}}$
- 3. Считаем p-value  $P(T \ge t) = \frac{1}{B} \sum_{b=1}^{B} 1\{T^{*(b)} \ge t\}$

где B – количество бут-итераци, t – значение статистики на уровне альфы (например 1.96 для 95% уровня значимости)